Εθνικό Μετσόβιο Πολυτεχνείο

Σχολή Ηλεκτρολόγων Μηχανικών και Μηχανικών Υπολογιστών

3η Εργαστηριακή Άσκηση

Εισαγωγική εργασία στο High Level Synthesis

Μάθημα: Σχεδιασμός Ενσωματωμένων Συστημάτων

Εξάμηνο: 9ο

Ονοματεπώνυμα: Μιχαλακόπουλος Δημήτριος (ΑΜ: 03120229), Γκενάκου Ζωή (ΑΜ: 03120015)

Εισαγωγή

Η συγκεκριμένη εργασία επικεντρώνεται στη βελτιστοποίηση μιας εφαρμογής Recommendation System (RS) που εκτελείται στο σύστημα Zynq-7000 ARM/FPGA SoC (Zybo). Στόχος είναι η αξιοποίηση του FPGA για την επίσπευση των υπολογιστικών διαδικασιών, αξιοποιώντας τεχνικές High-Level Synthesis (HLS).

Εφαρμογή

Η υπό μελέτη εφαρμογή αποτελεί ένα υλοποιημένο RS που βασίζεται στον αλγόριθμο K-Nearest Neighbor (KNN) και χρησιμοποιεί ένα υποσύνολο του MovieLens dataset. Το dataset περιλαμβάνει πληροφορίες όπως:

- **ID ταινίας**
- **Όνομα ταινίας**
- **Βαθμολογίες χρηστών** για κάθε ταινία.

Ο αλγόριθμος KNN, με βάση αυτές τις πληροφορίες, προτείνει τις 10 πιο συναφείς ταινίες σε σχέση με μια δεδομένη ταινία-εισόδου. Στην υλοποίηση αυτή, εξετάζονται διαφορετικές μετρικές απόστασης που καθορίζουν τον βαθμό συνάφειας.

Σύστημα

Το σύστημα που χρησιμοποιείται είναι το **Zynq-7000 ARM/FPGA SoC (Zybo)**, το οποίο συνδυάζει:

1. **Processing System (PS)**: Βασίζεται στην αρχιτεκτονική ARM Cortex-A9 και περιλαμβάνει:
    - Μνήμες cache
    - On-chip και external memory interfaces
    - DMA controllers
    - I/O περιφερειακά
    - Διασυνδέσεις (interconnects).
2. **Programmable Logic (PL)**: Περιλαμβάνει πόρους FPGA, όπως:
    - Configurable Logic Blocks (CLB) που περιέχουν:
        - Look-Up Tables (LUT)
        - Flip Flops
        - Cascadable Adders
    - Block RAM (BRAM) 36KB
    - Digital Signal Processing Blocks (DSP)
    - I/O Blocks.

Αυτή η συνδυαστική αρχιτεκτονική επιτρέπει την ενσωμάτωση του λογισμικού με επιταχυντές υλικού, εξασφαλίζοντας ευελιξία και υψηλή απόδοση.

Σκοπός

Η εργασία επικεντρώνεται στον **αλγόριθμο KNN**, ο οποίος υπολογίζει την απόσταση μεταξύ ταινιών για να εντοπίσει τους κοντινότερους "γείτονες". Ειδικότερα:

1. Δέχεται ως είσοδο:
    - Ένα dataset με δεδομένα ταινιών και βαθμολογίες χρηστών.
    - Την ταινία προς σύσταση (movie ID).
2. Υπολογίζει την απόσταση της ταινίας αυτής από κάθε άλλη στο dataset.
3. Επιστρέφει τις **10 πιο συναφείς ταινίες**.

Μετρικές Απόστασης

Η απόσταση μεταξύ ταινιών υπολογίζεται με διαφορετικές μεθόδους:

- **Manhattan**: Απόσταση που βασίζεται στο άθροισμα απόλυτων διαφορών.
- **Cosine**: Υπολογίζει τη γωνιακή απόσταση (1 - συνημίτονο).
- **Minkowski**: Γενική μορφή απόστασης που περιλαμβάνει άλλες ως ειδικές περιπτώσεις.
- **Hamming**: Βασίζεται στις δυαδικές διαφορές.
- **Euclidean**: Απόσταση σε επίπεδο Καρτεσιανό χώρο.

Η κάθε μέθοδος ενσωματώνει διαφορετικά χαρακτηριστικά, προσφέροντας δυνατότητα επιλογής ανάλογα με τις ανάγκες της εφαρμογής.

Βελτιστοποίηση

Η συγκεκριμένη υλοποίηση επικεντρώνεται στην **ευκλείδεια απόσταση** (Euclidean), η οποία είναι υπολογιστικά απαιτητική λόγω των πολλαπλών πράξεων ανά ζεύγος ταινιών. Ένα μεγάλο μέρος της εφαρμογής αφιερώνεται:

- Στην ανάγνωση/εγγραφή δεδομένων από τη μνήμη.
- Στον υπολογισμό των αποστάσεων.

Η εργασία μελετά τη μεταφορά του υπολογιστικού φορτίου στο FPGA, ώστε να επιταχυνθεί η διαδικασία. Οι επιδόσεις αξιολογούνται με βάση:

1. **Πλήθος κύκλων**: Ο αριθμός κύκλων ρολογιού που απαιτείται για την ολοκλήρωση της διαδικασίας.
2. **Speedup (Επιτάχυνση)**: Ο λόγος μεταξύ χρόνου εκτέλεσης σε λογισμικό (SW) και σε υλικό (HW). Μια τιμή μεγαλύτερη του 1 δηλώνει αυξημένη απόδοση.

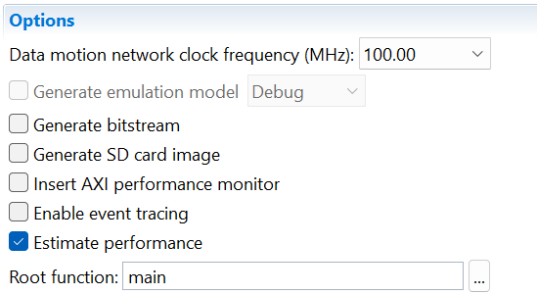
Η βελτιστοποίηση στοχεύει στη μείωση του αριθμού κύκλων και στην αύξηση του speedup μέσω:

- Χρήσης HLS directives.
- Παραλληλοποίησης (pipelining/unrolling).
- Custom data types για καλύτερη διαχείριση πόρων.

Άσκηση 1

Στόχος του Ζητούμενου 1 είναι η αξιολόγηση και βελτιστοποίηση της συνάρτησης `calcDistancesHW`, η οποία υλοποιεί την πιο υπολογιστικά εντατική διαδικασία του Recommendation System: τον υπολογισμό ευκλείδειων αποστάσεων. Η εργασία διακρίνεται σε τρία στάδια:

A. Αρχική Εκτίμηση Επιδόσεων: Με χρήση του εργαλείου SDSoC 2016.4 εκτιμάται το πλήθος των απαιτούμενων κύκλων για την εκτέλεση της συνάρτησης `calcDistancesHW` στο FPGA και αναλύεται η χρήση των υπολογιστικών πόρων του PL.



Χρησιμοποιήσαμε την προκαθορισμένη υλοποίηση της calcDistancesHW και πραγματοποιήσαμε Estimate Performance χωρίς καμία βελτιστοποίηση. Η συνάρτηση χωρίζεται σε τέσσερα διακριτά μέρη:

- **LOAD_DATA_HW_TMP**: Φορτώνει τα δεδομένα από τη μνήμη στο FPGA.
- **LOAD_MOVIE_TMP**: Φορτώνει τα δεδομένα της ταινίας-στόχου.
- **COMPUTE_DISTS**: Υπολογίζει τις ευκλείδειες αποστάσεις.
- **WRITE_DISTS**: Επιστρέφει τις αποστάσεις στον host

Details

Performance estimates for 'calcDistancesHW in main.cpp:24 ...

HW accelerated (Estimated cycles)	3244037

Resource utilization estimates for HW functions

Resource	Used	Total	% Utilization
DSP	5	80	6,25
BRAM	33	60	55
LUT	1652	17600	9,39
FF	1060	35200	3,01

Performance Estimates

Timing (ns)

Summary

Clock	Target	Estimated	Uncertainty
ap_clk	10.00	8.68	1.25

Latency (clock cycles)

Summary

Detail

Instance

Loop

	Latency			Initiation Interval			
Loop Name	min	max	Iteration Latency	achieved	target	Trip Count	Pipelined
- LOAD_DATA_HW_TMP	34816	34816	34	-	-	1024	no
+ LOAD_DATA_HW_TMP.1	32	32	1	-	-	32	no
- LOAD_MOVIE_TMP	64	64	2	-	-	32	no
- COMPUTE_DISTS	438272	438272	428	-	-	1024	no
+ COMPUTE_DISTS.1	416	416	13	-	-	32	no
- WRITE_DISTS	2048	2048	2	-	-	1024	no

Αποτελέσματα

- Απαιτούμενοι κύκλοι: **3,244,037**.
- Παρατηρήθηκε μέτρια χρήση υπολογιστικών πόρων του FPGA, με αξιοποίηση μνήμης >50%.

Σχόλια

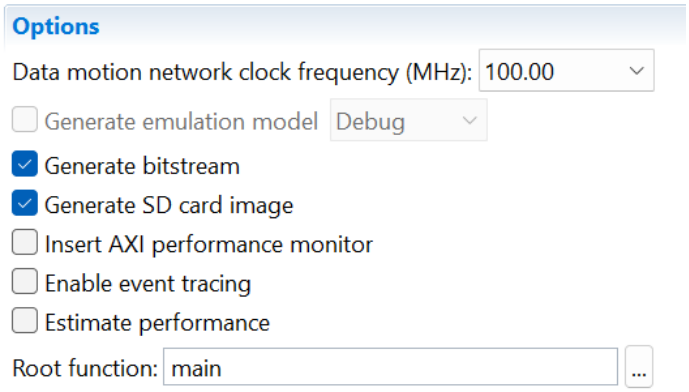
Η αρχική εκτίμηση ανέδειξε ότι:

- Το **COMPUTE_DISTS** αποτελεί το πιο υπολογιστικά εντατικό μέρος της συνάρτησης, απαιτώντας το μεγαλύτερο αριθμό κύκλων.
- Το **LOAD_DATA_HW_TMP** και το **WRITE_DISTS** επίσης έχουν σημαντικό κόστος λόγω των μεγάλων όγκων δεδομένων που διακινούνται.

Αυτή η ανάλυση τονίζει την ανάγκη για βελτιστοποίηση της διαδικασίας υπολογισμών και της διαχείρισης δεδομένων.

B. Για το επόμενο ζητούμενο, φτιάχνουμε το αρχείο `sd_card`, το οποίο περιέχει:

- Το εκτελέσιμο αρχείο (`.elf`) για την ARM CPU.
- Το bitstream για τη ρύθμιση του FPGA.
- Τη διαμόρφωση του λειτουργικού συστήματος (PetaLinux).



Παραθέτουμε τα αποτελέσματα μετά την εκτέλεση της εφαρμογής:

COM8 - PuTTY

```
Qdpgw2InC3//mpDLihnbJX8zsUK9Pa/3kjcIWWLLLgfQhrnStHnO/WYPJxEovQAA2l root@Avnet-Digilent-ZedBoard-2016_3
Fingerprint: md5 0d:58:09:a0:7d:cc:1d:8d:2b:33:26:77:40:15:50:13
dropbear.
hwclock: can't open '/dev/misc/rtc': No such file or directory
Starting tcf-agent: OK

sh-4.3# ls
bin      dev      home     install  media    proc     sbin     tmp      var
boot     etc      init     lib      mnt      run      sys      usr
sh-4.3# cd mnt
sh-4.3# ls
BOOT.BIN                  System Volume Information  embedded.elf
FOUND.000                 _sds                       image.ub
README.txt                dataset.csv                nameIdMapping.csv
sh-4.3# ./embedded.elf
Started reading dataset...
Finished reading dataset...
Started reading name id mapping...
Finished reading name id mapping...
Input movie id = 0
Started distance calculations on software...
Finished distance calculations on software...
Started distance calculations on hardware...
Finished distance calculations on hardware...

Recommendation system start to make inference
...
Recommendations for movie with id 0:
0. Jurassic Park (1993), with distance of 10.7121
1. Fish Called Wanda  A (1988), with distance of 11.0793
2. Back to the Future (1985), with distance of 11.6404
3. Star Wars: Episode VI - Return of the Jedi (1983), with distance of 11.8849
4. Lion King  The (1994), with distance of 12.0623
5. Raising Arizona (1987), with distance of 12.1552
6. Wizard of Oz  The (1939), with distance of 12.1861
7. Batman (1989), with distance of 12.2066
8. Princess Bride  The (1987), with distance of 12.3085
9. E.T. the Extra-Terrestrial (1982), with distance of 12.3996

Hardware cycles : 3264670
Software cycles : 1389967
Speedup         : 0.42576
Correct = 1024, Score = 1.000000
sh-4.3#
```

Αποτελέσματα

- *FPGA Εκτέλεση*: Απαιτούμενοι κύκλοι: 3,264,670 (σχεδόν ίδιοι με την εκτίμηση του 1.A).
- *CPU Εκτέλεση*: Απαιτούμενοι κύκλοι: 1,389,967.
- *Speedup*: 0.42576.

Σχόλια

Παρατηρήσαμε ότι η η εκτέλεση των υπολογισμών των αποστάσεων σε FPGA αντί για MCU μείωσε σημαντικά την επίδοση της εφαρμογής. Αυτό αποδίδεται σε:

- Έλλειψη βελτιστοποίησης: Το υπάρχον design δεν αξιοποιεί την παράλληλη φύση του FPGA.
- Overhead μεταφοράς δεδομένων: Η κίνηση δεδομένων μεταξύ host και FPGA προσθέτει καθυστέρηση.

C. Σε αυτό το σημείο καλούμαστε να κάνουμε optimizations ώστε να επιταχυνθεί ο αλγόριθμος. Δοκιμάζουμε διάφορα HLS directives και βλέπουμε το αποτέλεσμα του estimation.

Τα **High-Level Synthesis (HLS) directives** είναι οδηγίες που χρησιμοποιούνται για τη βελτιστοποίηση κώδικα υψηλού επιπέδου (π.χ., C, C++) κατά τη διαδικασία μετάφρασής του σε hardware design. Τα directives καθοδηγούν τον μεταγλωττιστή HLS να παράγει πιο αποδοτικό hardware design, ρυθμίζοντας πτυχές όπως η χρήση πόρων, η παράλληλη εκτέλεση, η πρόσβαση στη μνήμη και ο έλεγχος καθυστερήσεων.

Τα **pragmas** είναι ειδικές εντολές που εισάγονται στον κώδικα μέσω σχολίων. Σε συστήματα HLS, τα pragmas είναι οδηγίες που δεν επηρεάζουν τη λειτουργική συμπεριφορά του κώδικα αλλά κατευθύνουν τον μεταγλωττιστή να αλλάξει τον τρόπο που παράγει το hardware.

Εφαρμόστηκαν HLS directives για να βελτιστοποιήσουμε το σχεδιασμό και να μειώσουμε τους απαιτούμενους κύκλους:

```
#include <math.h>

#include "calcDist.h"

void calcDistancesHW(float *data_hw, float *dists_hw)

{
```

```
    float data_hw_tmp[MOVIES_NUM][USERS_NUM];

    float movie_tmp[USERS_NUM];

    float dists_hw_tmp[MOVIES_NUM];

#pragma HLS array_partition variable = data_hw_tmp block factor = 4 dim =
2

LOAD_DATA_HW_TMP:

    for (int i = 0; i < MOVIES_NUM; i++)

    {

        for (int j = 0; j < USERS_NUM; j++)

        {

#pragma HLS PIPELINE II=1

            data_hw_tmp[i][j] = data_hw[i * USERS_NUM + j];

        }

    }



LOAD_MOVIE_TMP:

    for (int i = 0; i < USERS_NUM; i++)

    {

#pragma HLS PIPELINE II=1

        movie_tmp[i] = data_hw_tmp[MOVIE_ID][i];

    }



COMPUTE_DISTS:

    for (int i = 0; i < MOVIES_NUM; i++)
```

```
    {
#pragma HLS PIPELINE II=1
        float sum = 0.0, diff = 0.0;
        for (int j = 0; j < USERS_NUM; j++)
        {
#pragma HLS UNROLL
            diff = data_hw_tmp[i][j] - movie_tmp[j];
            sum += diff * diff;
        }
        dists_hw_tmp[i] = sqrt(sum);
    }


WRITE_DISTS:
    for (int i = 0; i < MOVIES_NUM; i++)
    {
#pragma HLS PIPELINE II=1
        dists_hw[i] = dists_hw_tmp[i];
    }
}
```

Εξηγήσεις

```
#pragma HLS array_partition variable = data_hw_tmp block factor= 4 dim= 2
```

Το **`#pragma HLS ARRAY_PARTITION`** χωρίζει έναν πίνακα σε πολλαπλούς υποπίνακες για παράλληλη πρόσβαση σε στοιχεία. Αυτό αυξάνει την αποδοτικότητα του hardware, ειδικά όταν οι προσβάσεις στη μνήμη του πίνακα είναι συχνές.

Το directive χωρίζει τη δεύτερη διάσταση (`dim=2`) σε **4 υποπίνακες** (`factor=4`), δημιουργώντας 4 πίνακες που ο καθένας έχει:

- **1024 γραμμές**.
- **8 στήλες** (32 στήλες διαιρούμενες σε 4 υποπίνακες).

Δηλαδή:

```
data_hw_tmp[1024][32]
```

Γίνεται:

```
data_hw_tmp_1[1024][8]
data_hw_tmp_2[1024][8]
data_hw_tmp_3[1024][8]
data_hw_tmp_4[1024][8]
```

```
#pragma HLS PIPELINE II=1
```

Το directive `#pragma HLS PIPELINE II=1` χρησιμοποιείται στο πλαίσιο της High-Level Synthesis (HLS) για τη βελτιστοποίηση βρόχων ή συναρτήσεων, με στόχο το pipelining των επαναλήψεων.

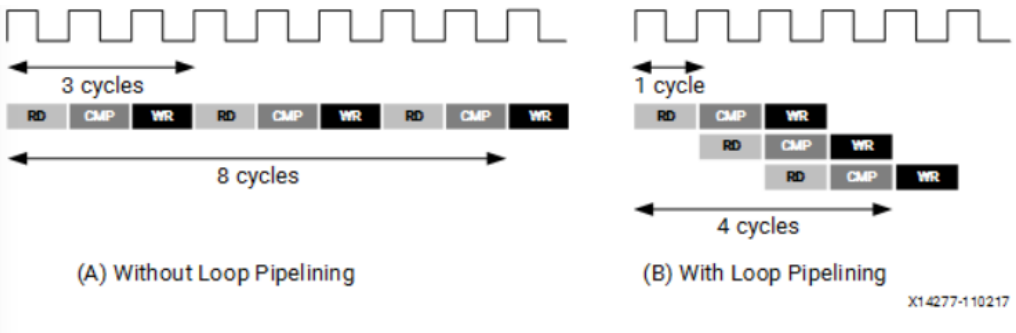
- Το **`II=1` (Initiation Interval)** καθορίζει ότι κάθε νέο iteration του βρόχου θα ξεκινά σε **κάθε κύκλο ρολογιού**.

Χωρίς Pipelining:

- Οι επαναλήψεις ενός βρόχου εκτελούνται **διαδοχικά** (serial execution), όπου κάθε επανάληψη πρέπει να ολοκληρωθεί πριν ξεκινήσει η επόμενη.

Με Pipelining (`II=1`):

- Τα iterations εκτελούνται **παράλληλα** (overlapping execution), και ένα νέο iteration ξεκινά σε κάθε κύκλο ρολογιού.
- Ο μεταγλωττιστής HLS δημιουργεί hardware stages, όπου κάθε stage εκτελεί ένα μέρος της επανάληψης.




```
#pragma HLS UNROLL
```

Το directive `#pragma HLS UNROLL` χρησιμοποιείται στη High-Level Synthesis (HLS) για την κατάργηση (unrolling) των βρόχων. Καταργώντας έναν βρόχο, το HLS δημιουργεί ξεχωριστές hardware μονάδες για κάθε iteration του βρόχου, επιτρέποντας την ταυτόχρονη εκτέλεση όλων των iterations.

Όταν εφαρμόζεται σε έναν βρόχο, το `#pragma HLS UNROLL`:

- **Μετατρέπει** κάθε iteration του βρόχου σε ξεχωριστή λογική μονάδα hardware.
- Όλα τα iterations εκτελούνται **ταυτόχρονα** (παράλληλη εκτέλεση).
- **Παραλείπει** τη χρήση ενός counter για τη διαχείριση του βρόχου, μειώνοντας την εξάρτηση από διαδοχική εκτέλεση.

```
#pragma HLS UNROLL [factor=<N>]
```

`factor=<N>`: Καθορίζει τον αριθμό των iterations που θα εκτελεστούν ταυτόχρονα.

- Αν δεν οριστεί, γίνεται πλήρης κατάργηση (complete unrolling).

Θα δοκιμάσουμε αυτά τα HLS directives και θα δοκιμάσουμε να κάνουμε complete unrolling, unrolling με factor = 4 και unrolling με factor = 8.
Τα estimations που παράχθηκαν ήταν παρόμοια και στις τρεις περιπτώσεις:

Details

Performance estimates for 'calcDistancesHW in main.cpp:24 ...

HW accelerated (Estimated cycles)	402796

Resource utilization estimates for HW functions

Resource	Used	Total	% Utilization
DSP	56	80	70
BRAM	34	60	56,67
LUT	12960	17600	73,64
FF	10471	35200	29,75

Performance Estimates

Timing (ns)

Summary

Clock	Target	Estimated	Uncertainty
ap_clk	10.00	8.68	1.25

Latency (clock cycles)

Summary

Detail

Instance

Loop

Loop Name	Latency min	Latency max	Iteration Latency	Initiation Interval achieved	Initiation Interval target	Trip Count	Pipelined
- LOAD_DATA_HW_TMP	32768	32768	33	32	1	1024	yes
- LOAD_MOVIE_TMP	32	32	2	1	1	32	yes
- COMPUTE_DISTS	4242	4242	151	4	1	1024	yes
- WRITE_DISTS	1024	1024	2	1	1	1024	yes

Εξάγοντας τα bitstream για τις τρεις υλοποιήσεις βλέπουμε στο τερματικό τα εξής αποτελέσματα:

```
#pragma HLS UNROLL
```

```
sh-4.3# ./embedded.elf
Started reading dataset...
Finished reading dataset...
Started reading name id mapping...
Finished reading name id mapping...
Input movie id = 0
Started distance calculations on software...
Finished distance calculations on software...
Started distance calculations on hardware...
Finished distance calculations on hardware...

Recommendation system start to make inference
...
Recommendations for movie with id 0:
0. Jurassic Park (1993), with distance of 10.7121
1. Fish Called Wanda  A (1988), with distance of 11.0793
2. Back to the Future (1985), with distance of 11.6404
3. Star Wars: Episode VI - Return of the Jedi (1983), with distance of 11.8849
4. Lion King  The (1994), with distance of 12.0623
5. Raising Arizona (1987), with distance of 12.1552
6. Wizard of Oz  The (1939), with distance of 12.1861
7. Batman (1989), with distance of 12.2066
8. Princess Bride  The (1987), with distance of 12.3085
9. E.T. the Extra-Terrestrial (1982), with distance of 12.3996

Hardware cycles : 421970
Software cycles : 1389846
Speedup         : 3.29371
Correct = 1024, Score = 1.000000
sh-4.3#
```

```
#pragma HLS UNROLL factor = 4
```

```
sh-4.3# cd mnt
sh-4.3# ./embedded.elf
Started reading dataset...
Finished reading dataset...
Started reading name id mapping...
Finished reading name id mapping...
Input movie id = 0
Started distance calculations on software...
Finished distance calculations on software...
Started distance calculations on hardware...
Finished distance calculations on hardware...

Recommendation system start to make inference
...
Recommendations for movie with id 0:
0. Jurassic Park (1993), with distance of 10.7121
1. Fish Called Wanda  A (1988), with distance of 11.0793
2. Back to the Future (1985), with distance of 11.6404
3. Star Wars: Episode VI - Return of the Jedi (1983), with distance of 11.8849
4. Lion King  The (1994), with distance of 12.0623
5. Raising Arizona (1987), with distance of 12.1552
6. Wizard of Oz  The (1939), with distance of 12.1861
7. Batman (1989), with distance of 12.2066
8. Princess Bride  The (1987), with distance of 12.3085
9. E.T. the Extra-Terrestrial (1982), with distance of 12.3996

Hardware cycles : 421456
Software cycles : 1390877
Speedup         : 3.30017
Correct = 1024, Score = 1.000000
sh-4.3#
```

```
#pragma HLS UNROLL factor = 8
```

```
sh-4.3# cd mnt/
sh-4.3# ./embedded.elf
Started reading dataset...
Finished reading dataset...
Started reading name id mapping...
Finished reading name id mapping...
Input movie id = 0
Started distance calculations on software...
Finished distance calculations on software...
Started distance calculations on hardware...
Finished distance calculations on hardware...

Recommendation system start to make inference
...
Recommendations for movie with id 0:
0. Jurassic Park (1993), with distance of 10.7121
1. Fish Called Wanda  A (1988), with distance of 11.0793
2. Back to the Future (1985), with distance of 11.6404
3. Star Wars: Episode VI - Return of the Jedi (1983), with distance of 11.8849
4. Lion King  The (1994), with distance of 12.0623
5. Raising Arizona (1987), with distance of 12.1552
6. Wizard of Oz  The (1939), with distance of 12.1861
7. Batman (1989), with distance of 12.2066
8. Princess Bride  The (1987), with distance of 12.3085
9. E.T. the Extra-Terrestrial (1982), with distance of 12.3996

Hardware cycles : 423335
Software cycles : 1390270
Speedup         : 3.28409
Correct = 1024, Score = 1.000000
sh-4.3#
```

Pipelined Design

Παρατηρούμε από το Initiation Interval (II) στην αναφορά ότι το design είναι pipelined, με εξαίρεση:

- Ο βρόχος **COMPUTE_DISTS** έχει II=4.
    - Το **II=4** είναι σχετικά χαμηλό, αλλά υποδεικνύει ότι ο βρόχος δεν έχει πλήρη pipelining. Αυτό μπορεί να οφείλεται σε εξαρτήσεις μεταξύ των επαναλήψεων μπορεί να καθυστερούν τη pipelining διαδικασία.

- Ο βρόχος **LOAD_DATA_HW_TMP** έχει II=32, που τον καθιστά το bottleneck του συστήματος, καθώς απαιτεί το μεγαλύτερο αριθμό κύκλων (32,768), δηλαδή η φόρτωση των δεδομένων από τη μνήμη είναι το κύριο σημείο συμφόρησης του συστήματος.

Συγκριτική Ανάλυση Αποτελεσμάτων

Κατάσταση	HW Cycles	SW Cycles	Speedup
Unoptimized	3,264,670	1,389,967	0.42576
Optimized (UF=1)	421,970	1,389,846	3.29371
Optimized (UF=4)	421,456	1,390,877	3.30017
Optimized (UF=8)	423,335	1,390,270	3.28409

Παρατηρήσεις

1. Το **Unoptimized Design** παρουσιάζει πολύ χαμηλό **speedup (0.42)**, καθώς η υλοποίηση δεν αξιοποιεί την παράλληλη φύση του FPGA.
2. Με **unrolling factor = 4**, πετυχαίνεται το καλύτερο speedup (**3.30017**), υποδεικνύοντας ότι η παράλληλη εκτέλεση βελτιώνει δραστικά την απόδοση.
3. Η βελτιστοποίηση με **unrolling Factor = 4** μειώνει τους κύκλους κατά **87%** σε σχέση με το unoptimized design.

4. Το speedup αυξάνεται σχεδόν **7 φορές** σε σχέση με το unoptimized design.

5. **Χρήση Πόρων FPGA**:
    a. Η χρήση DSPs αυξήθηκε από 6.25% σε **70%**.
    b. Η χρήση LUTs αυξήθηκε από 9.39% σε **73.64%**.
    c. Αυτό δείχνει ότι οι βελτιώσεις αξιοποιούν καλύτερα τους πόρους του FPGA, αν και οι απαιτήσεις αυξάνονται.

6. Κοιτώντας τους estimated κύκλους για κάθε μέρος της συνάρτησης **calcDistancesHW**, παρατηρούμε τα εξής: Το κομμάτι των υπολογισμών των αποστάσεων (**COMPUTE_DISTS**), που προηγουμένως ήταν ο κύριος παράγοντας καθυστέρησης του προγράμματος, έχει σημειώσει **99% μείωση στους απαιτούμενους κύκλους**.

Άσκηση 2

Στο συγκεκριμένο ερώτημα, αντικαθιστούμε τους κλασικούς τύπους δεδομένων (π.χ. `float`) στον κώδικα του FPGA με custom τύπους από τη βιβλιοθήκη **ap_fixed.h**. Χρησιμοποιείται ο τύπος **ap_ufixed**, ο οποίος επιτρέπει τον καθορισμό ακρίβειας με ακέραιο και δεκαδικό μέρος.

Στο αρχείο `calcDist.h`, ορίζεται ο τύπος:

```
typedef ap_ufixed<INT_BITS + DEC_BITS, INT_BITS, AP_RND> DTYPE1;
```

- **`INT_BITS`**: Ορίζει τον αριθμό των bits για το ακέραιο μέρος.
- **`DEC_BITS`**: Ορίζει τον αριθμό των bits για το δεκαδικό μέρος.
- **`AP_RND`**: Χρησιμοποιείται για τη στρογγυλοποίηση κατά την εκτέλεση πράξεων.

Δεδομένα Εισόδου

1. Βαθμολογίες ταινιών:
    - Οι βαθμολογίες κυμαίνονται από 0.0 έως 5.0 με βήμα 0.5.
    - Δεν απαιτείται ακρίβεια μεγαλύτερη από 1 δεκαδικό ψηφίο για τις βαθμολογίες.
2. Αριθμός χρηστών (USERS_NUM):
    - Για κάθε ταινία, υπάρχουν 32 βαθμολογίες χρηστών.
3. Αριθμός ταινιών (MOVIES_NUM):
    - Υπάρχουν 1024 ταινίες, για τις οποίες υπολογίζουμε την απόσταση από μία συγκεκριμένη ταινία.

Ο πιο κρίσιμος υπολογισμός στον κώδικα πραγματοποιείται στη συνάρτηση **COMPUTE_DISTS**, όπου υπολογίζεται η ευκλείδεια απόσταση:

```
diff = data_hw_tmp[i][j] - movie_tmp[j];
sum += diff * diff;
```

Το `diff` είναι η διαφορά δύο βαθμολογιών και κυμαίνεται από **-5.0 έως +5.0**.

Το `sum` είναι το άθροισμα τετραγώνων διαφορών:

```
sum = Σ(diff^2) για 32 χρήστες
sum = 32 * (5.0)^2 = 800.0 (μέγιστο)
```

Το INT_BITS καθορίζει το μέγιστο εύρος τιμών που μπορεί να αναπαραστήσει ο custom τύπος:

- Για το `sum`, που μπορεί να φτάσει μέχρι και 800.0, απαιτούνται τουλάχιστον **10 bits**:
  - $2^{10} = 1024 > 800$

Η ακρίβεια ενός δεκαδικού ψηφίου (DEC_BITS = 2) είναι **επαρκής** για την εφαρμογή του KNN με Ευκλείδεια Απόσταση, καθώς οι βαθμολογίες και οι πράξεις δεν απαιτούν μεγαλύτερη ακρίβεια. Ταυτόχρονα, αυτή η επιλογή μειώνει την κατανάλωση πόρων και επιταχύνει την εκτέλεση στο FPGA.

Ως αποτέλεσμα, θα δοκιμάσουμε τους παρακάτω συνδυασμούς:

1. **INT = 4, DEC = 12**
2. **INT = 6, DEC = 10**
3. **INT = 8, DEC = 4**
4. **INT = 8, DEC = 8**
5. **INT = 10, DEC = 2**
6. **INT = 10, DEC = 6**
7. **INT = 12, DEC = 2**
8. **INT = 12, DEC = 4**
9. **INT = 14, DEC = 2**
10. **INT = 16, DEC = 8**
11. **INT = 10, DEC = 2 + HLS Directives**

Για τις παραπάνω τιμές κάνουμε Estimate Performance, ξεκινώντας με την αρχική τιμή που μας δίνεται:

```
#define INT_BITS 16
#define DEC_BITS 8
```

Details

Performance estimates for 'calcDistancesHW in main.cpp:24 ...

HW accelerated (Estimated cyc	2006021

Resource utilization estimates for HW functions

Resource	Used	Total	% Utilization
DSP	2	80	2.5
BRAM	25	60	41.67
LUT	2329	17600	13.23
FF	1230	35200	3.49

General Information

Date:	Tue Nov 26 23:38:45 2024
Version:	2016.4 (Build 1722992 on Wed Mar 08 18:30:27 MST 2017)
Project:	calcDistancesHW
Solution:	solution
Product family:	zynq
Target device:	xc7z010clg400-2

Performance Estimates

Timing (ns)

Summary

Clock	Target	Estimated	Uncertainty
ap_clk	10.00	8.70	1.25

Latency (clock cycles)

Summary

Latency		Interval		
min	max	min	max	Type
284740	284740	284741	284741	none

Detail

Instance

Loop

	Latency			Initiation Interval			
Loop Name	min	max	Iteration Latency	achieved	target	Trip Count	Pipelined
- LOAD_DATA_HW_TMP	133120	133120	130	-	-	1024	no
+ LOAD_DATA_HW_TMP.1	128	128	4	-	-	32	no
- LOAD_MOVIE_TMP	64	64	2	-	-	32	no
- COMPUTE_DISTS	149504	149504	146	-	-	1024	no
+ COMPUTE_DISTS.1	128	128	4	-	-	32	no
- WRITE_DISTS	2048	2048	2	-	-	1024	no

Όλοι οι συνδυασμοί που δοκιμάσαμε έχουν παρόμοια estimated αποτελέσματα, πέρα από μερικές βελτιώσεις στο resource utilization, όπως φαίνεται παρακάτω με τον συνδυασμό:

```
#define INT_BITS 10
#define DEC_BITS 2
```

Details

Performance estimates for 'calcDistancesHW in main.cpp:24 ...

HW accelerated (Estimated cyc	2006021

Resource utilization estimates for HW functions

Resource	Used	Total	% Utilization
DSP	1	80	1.25
BRAM	13	60	21.67
LUT	2176	17600	12.36
FF	1138	35200	3.23

Synthesis Report for 'calcDistancesHW'

General Information

Date:	Wed Nov 27 00:26:13 2024
Version:	2016.4 (Build 1722992 on Wed Mar 08 18:30:27 MST 2017)
Project:	calcDistancesHW
Solution:	solution
Product family:	zynq
Target device:	xc7z010clg400-2

Performance Estimates

Timing (ns)

Summary

Clock	Target	Estimated	Uncertainty
ap_clk	10.00	8.70	1.25

Latency (clock cycles)

Summary

Latency		Interval		
min	max	min	max	Type
284740	284740	284741	284741	none

Detail

Instance

Loop

	Latency			Initiation Interval			
Loop Name	min	max	Iteration Latency	achieved	target	Trip Count	Pipelined
- LOAD_DATA_HW_TMP	133120	133120	130	-	-	1024	no
+ LOAD_DATA_HW_TMP.1	128	128	4	-	-	32	no
- LOAD_MOVIE_TMP	64	64	2	-	-	32	no
- COMPUTE_DISTS	149504	149504	146	-	-	1024	no
+ COMPUTE_DISTS.1	128	128	4	-	-	32	no
- WRITE_DISTS	2048	2048	2	-	-	1024	no

Δημιουργώντας το bitstream και εκτελώντας τους παραπάνω συνδυασμούς και στο Zybo παραθέτουμε ορισμένα από τα αποτελέσματα:

```
#define INT_BITS 8
#define DEC_BITS 8
```

```
sh-4.3# ./exercise3b.elf
Started reading dataset...
Finished reading dataset...
Started reading name id mapping...
Finished reading name id mapping...
Input movie id = 0
Started distance calculations on software...
Finished distance calculations on software...
Started distance calculations on hardware...
Finished distance calculations on hardware...

Recommendation system start to make inference
...
Recommendations for movie with id 0:
0. Liar Liar (1997), with distance of 0
1. Birds  The (1963), with distance of 1.22474
2. Space Jam (1996), with distance of 1.32288
3. Cape Fear (1962), with distance of 1.32288
4. Taxi Driver (1976), with distance of 1.65831
5. Get Shorty (1995), with distance of 1.80278
6. Johnny Mnemonic (1995), with distance of 1.80278
7. Alien (1979), with distance of 1.93649
8. Nightmare on Elm Street  A (1984), with distance of 2.17945
9. Graduate  The (1967), with distance of 2.23607

Hardware cycles : 2025007
Software cycles : 1390331
Speedup         : 0.686581
dists[2] = 18.3644, dists_hw[2] = 9.01388
dists[3] = 18.7083, dists_hw[3] = 9.69536
dists[4] = 18.2757, dists_hw[4] = 8.83176
dists[5] = 16.2096, dists_hw[5] = 2.59808
```

```
dists[1013] = 18.4662, dists_hw[1013] = 9.21954
dists[1014] = 16.4241, dists_hw[1014] = 3.7081
dists[1015] = 16.7033, dists_hw[1015] = 4.79583
dists[1017] = 16.6808, dists_hw[1017] = 4.71699
dists[1018] = 18.7083, dists_hw[1018] = 9.69536
dists[1020] = 18.7083, dists_hw[1020] = 9.69536
dists[1021] = 18.7083, dists_hw[1021] = 9.69536
dists[1022] = 18.4932, dists_hw[1022] = 9.27362
dists[1023] = 18.7083, dists_hw[1023] = 9.69536
Correct = 142, Score = 0.138672
```

```
#define INT_BITS 10
#define DEC_BITS 2
```

```
sh-4.3# cd mnt/
sh-4.3# ./exercise3b.elf
Started reading dataset...
Finished reading dataset...
Started reading name id mapping...
Finished reading name id mapping...
Input movie id = 0
Started distance calculations on software...
Finished distance calculations on software...
Started distance calculations on hardware...
Finished distance calculations on hardware...

Recommendation system start to make inference
...
Recommendations for movie with id 0:
0. Jurassic Park (1993), with distance of 10.7121
1. Fish Called Wanda  A (1988), with distance of 11.0793
2. Back to the Future (1985), with distance of 11.6404
3. Star Wars: Episode VI - Return of the Jedi (1983), with distance of 11.8849
4. Lion King  The (1994), with distance of 12.0623
5. Raising Arizona (1987), with distance of 12.1552
6. Wizard of Oz  The (1939), with distance of 12.1861
7. Batman (1989), with distance of 12.2066
8. Princess Bride  The (1987), with distance of 12.3085
9. E.T. the Extra-Terrestrial (1982), with distance of 12.3996

Hardware cycles : 2025194
Software cycles : 1390235
Speedup         : 0.68647
Correct = 1024, Score = 1.000000
```

```
#define INT_BITS 14
#define DEC_BITS 2
```

```
sh-4.3# cd mnt/
sh-4.3# ./exercise3b.elf
Started reading dataset...
Finished reading dataset...
Started reading name id mapping...
Finished reading name id mapping...
Input movie id = 0
Started distance calculations on software...
Finished distance calculations on software...
Started distance calculations on hardware...
Finished distance calculations on hardware...

Recommendation system start to make inference
...
Recommendations for movie with id 0:
0. Jurassic Park (1993), with distance of 10.7121
1. Fish Called Wanda  A (1988), with distance of 11.0793
2. Back to the Future (1985), with distance of 11.6404
3. Star Wars: Episode VI - Return of the Jedi (1983), with distance of 11.8849
4. Lion King  The (1994), with distance of 12.0623
5. Raising Arizona (1987), with distance of 12.1552
6. Wizard of Oz  The (1939), with distance of 12.1861
7. Batman (1989), with distance of 12.2066
8. Princess Bride  The (1987), with distance of 12.3085
9. E.T. the Extra-Terrestrial (1982), with distance of 12.3996

Hardware cycles : 2026652
Software cycles : 1390136
Speedup         : 0.685927
Correct = 1024, Score = 1.000000
```

Τα αποτελέσματα φαίνονται και αναλυτικά παρακάτω:

EXERCISE 2	**HW_CYCLES**	**SW_CYCLES**	**SPEEDUP**	
Datatype INT=4 DEC=12	2025411	1390346	0.686451	**WRONG**
Datatype INT=6 DEC=10	2026824	1399755	0.685681	**WRONG**
Datatype INT=8 DEC=4	2026041	1390986	0.686554	**WRONG**
Datatype INT=8 DEC=8	2025007	1390331	0.686581	**WRONG**
Datatype INT=10 DEC=2	2025194	1390235	0.686470	**CORRECT**
Datatype INT=10 DEC=6	2025340	1389670	0.686142	**CORRECT**
Datatype INT=12 DEC=2	2026530	1390102	0.685952	**CORRECT**
Datatype INT=12 DEC=4	2025037	1389938	0.686377	**CORRECT**
Datatype INT=14 DEC=2	2026652	1390136	0.685927	**CORRECT**
Datatype INT=16 DEC=8	2025060	1390149	0.686473	**CORRECT**

Η βέλτιστη τιμή για να κάνυμε Estimate performance προσθέτοντας και τα HLS directives που είχαμε βάλει στο προηγούμενο ερώτημα, είναι η επιλογή **INT=10, DEC=2**, καθώς ισορροπεί με βέλτιστο τρόπο την ακρίβεια, την κατανάλωση πόρων και την απόδοση.

Με **INT=10**, το ακέραιο μέρος μπορεί να αναπαραστήσει αριθμούς έως και $2^{10} = 1024$, που είναι επαρκές για να καλύψει τις μέγιστες τιμές του αθροίσματος τετραγώνων διαφορών και με **DEC=2**, εξασφαλίζεται ακρίβεια **1 δεκαδικού ψηφίου**, που είναι αρκετή για τον υπολογισμό της ευκλείδειας απόστασης, αφού το τελικό αποτέλεσμα δεν απαιτεί περισσότερη ακρίβεια.

Ο συνδυασμός, επίσης, χρησιμοποιεί λιγότερους πόρους FPGA (DSPs, LUTs) σε σύγκριση με μεγαλύτερους τύπους όπως **INT=12** ή **DEC=6**.

Μικρότερο μέγεθος δεδομένων σημαίνει λιγότερο απαιτητική υλοποίηση στο FPGA, κάτι που επιτρέπει καλύτερη αξιοποίηση των διαθέσιμων πόρων.

Το **speedup** είναι υψηλό (**0.686470**) για τη συγκεκριμένη υλοποίηση, ενώ οι συνδυασμοί με μεγαλύτερες τιμές **DEC_BITS** ή **INT_BITS** έχουν ελαφρώς χαμηλότερο speedup.

Details

Performance estimates for 'calcDistancesHW in main.cpp:24 ...

HW accelerated (Estimated cycles)	402048

Resource utilization estimates for HW functions

Resource	Used	Total	% Utilization
DSP	32	80	40
BRAM	13	60	21,67
LUT	4558	17600	25,9
FF	2549	35200	7,24

Performance Estimates

Timing (ns)

Summary

Clock	Target	Estimated	Uncertainty
ap_clk	10.00	8.70	1.25

Latency (clock cycles)

Summary

Detail

Instance

Loop

Loop Name	Latency min	Latency max	Iteration Latency	Initiation Interval achieved	Initiation Interval target	Trip Count	Pipelined
- LOAD_DATA_HW_TMP_L	32771	32771	5	1	1	32768	yes
- LOAD_MOVIE_TMP	32	32	2	1	1	32	yes
- COMPUTE_DISTS	4124	4124	33	4	1	1024	yes
- WRITE_DISTS	1024	1024	2	1	1	1024	yes

```
sh-4.3# cd mnt/
sh-4.3# ./embedded.elf
Started reading dataset...
Finished reading dataset...
Started reading name id mapping...
Finished reading name id mapping...
Input movie id = 0
Started distance calculations on software...
Finished distance calculations on software...
Started distance calculations on hardware...
Finished distance calculations on hardware...

Recommendation system start to make inference
...
Recommendations for movie with id 0:
0. Jurassic Park (1993), with distance of 10.7121
1. Fish Called Wanda  A (1988), with distance of 11.0793
2. Back to the Future (1985), with distance of 11.6404
3. Star Wars: Episode VI - Return of the Jedi (1983), with distance of 11.8849
4. Lion King  The (1994), with distance of 12.0623
5. Raising Arizona (1987), with distance of 12.1552
6. Wizard of Oz  The (1939), with distance of 12.1861
7. Batman (1989), with distance of 12.2066
8. Princess Bride  The (1987), with distance of 12.3085
9. E.T. the Extra-Terrestrial (1982), with distance of 12.3996

Hardware cycles : 420946
Software cycles : 1390319
Speedup         : 3.30284
Correct = 1024, Score = 1.000000
sh-4.3#
```

EXERCISE 2	**HW_CYCLES**	**SW_CYCLES**	**SPEEDUP**	
INT=10 DEC=2+HLS dir	420946	1390319	3.30284	CORRECT

Στην περίπτωση **INT=10, DEC=2**, τα δεδομένα είναι μικρότερα σε μέγεθος σε σχέση με τον τύπο `float`:

- Ο custom τύπος δεδομένων χρησιμοποιεί **10 bits για το ακέραιο μέρος** και **2 bits για το δεκαδικό μέρος**, δηλαδή συνολικά **12 bits** ανά δεδομένο.
- Ο τύπος `float` τυπικά καταλαμβάνει **32 bits** ανά δεδομένο.

Παρατηρήσεις:

1. Μικρή Διαφορά στους HW Cycles:
    - Το fixed-point datatype μειώνει ελαφρώς τους κύκλους λόγω των απλούστερων πράξεων και της γρηγορότερης πρόσβασης στη μνήμη.
2. Πρακτικά Παρόμοιο Speedup:
    - Η διαφορά είναι μικρή, αλλά η χρήση custom datatypes αποδίδει ελαφρώς καλύτερα.

Άσκηση 3

Στο επόμενο ζητούμενο, για περαιτέρω βελτιστοποίηση της **COMPUTE_DISTS**, η δεύτερη διάσταση του πίνακα `data_hw_tmp` χωρίζεται σε περισσότερα blocks:

- **Block Factor = 8**
- **Block Factor = 16**

Αυτή η αλλαγή εισάγεται μέσω του directive:

```
#pragma HLS ARRAY_PARTITION variable = data_hw_tmp block factor = 8 dim = 2
```

```
#pragma HLS ARRAY_PARTITION variable = data_hw_tmp block factor = 16 dim = 2
```

Έπειτα, κάνουμε ακόμη μια αλλαγή κατά την οποία η διάσταση του πίνακα `movie_tmp` έχει πλήρη διαμερισμό, εισάγοντας το παρακάτω directive:

```
#pragma HLS ARRAY_PARTITION variable = movie_tmp complete dim = 1
```

Για την περίπτωση που το **Block Factor = 8** κάνουμε το estimation:

Details

Performance estimates for 'calcDistancesHW in main.cpp:24 ...

HW accelerated (Estimated cycles)	392601

Resource utilization estimates for HW functions

Resource	Used	Total	% Utilization
DSP	32	80	40
BRAM	13	60	21,67
LUT	4624	17600	26,27
FF	2453	35200	6,97

Performance Estimates

Timing (ns)

Summary

Clock	Target	Estimated	Uncertainty
ap_clk	10.00	8.70	1.25

Latency (clock cycles)

Summary

Detail

Instance

Loop

	Latency			Initiation Interval			
Loop Name	min	max	Iteration Latency	achieved	target	Trip Count	Pipelined
- LOAD_DATA_HW_TMP_L	32771	32771	5	1	1	32768	yes
- LOAD_MOVIE_TMP	32	32	2	1	1	32	yes
- COMPUTE_DISTS	2077	2077	32	2	1	1024	yes
- WRITE_DISTS	1024	1024	2	1	1	1024	yes

Η εκτέλεση στο Zybo:

```
sh-4.3# cd mnt/
sh-4.3# ./embedded.elf
Started reading dataset...
Finished reading dataset...
Started reading name id mapping...
Finished reading name id mapping...
Input movie id = 0
Started distance calculations on software...
Finished distance calculations on software...
Started distance calculations on hardware...
Finished distance calculations on hardware...

Recommendation system start to make inference
...
Recommendations for movie with id 0:
0. Jurassic Park (1993), with distance of 10.7121
1. Fish Called Wanda  A (1988), with distance of 11.0793
2. Back to the Future (1985), with distance of 11.6404
3. Star Wars: Episode VI - Return of the Jedi (1983), with distance of 11.8849
4. Lion King  The (1994), with distance of 12.0623
5. Raising Arizona (1987), with distance of 12.1552
6. Wizard of Oz  The (1939), with distance of 12.1861
7. Batman (1989), with distance of 12.2066
8. Princess Bride  The (1987), with distance of 12.3085
9. E.T. the Extra-Terrestrial (1982), with distance of 12.3996

Hardware cycles : 407203
Software cycles : 1390104
Speedup         : 3.41379
Correct = 1024, Score = 1.000000
sh-4.3#
```

Για την περίπτωση που το **Block Factor = 16** κάνουμε το estimation:

Details

Performance estimates for 'calcDistancesHW in main.cpp:24 ...

HW accelerated (Estimated cycles)	392601

Resource utilization estimates for HW functions

Resource	Used	Total	% Utilization
DSP	32	80	40
BRAM	17	60	28,33
LUT	4600	17600	26,14
FF	2430	35200	6,9

Performance Estimates

Timing (ns)

Summary

Clock	Target	Estimated	Uncertainty
ap_clk	10.00	8.70	1.25

Latency (clock cycles)

Summary

Detail

Instance

Loop

Loop Name	Latency min	Latency max	Iteration Latency	Initiation Interval achieved	Initiation Interval target	Trip Count	Pipelined
- LOAD_DATA_HW_TMP_L	32771	32771	5	1	1	32768	yes
- LOAD_MOVIE_TMP	32	32	2	1	1	32	yes
- COMPUTE_DISTS	1054	1054	32	1	1	1024	yes
- WRITE_DISTS	1024	1024	2	1	1	1024	yes

```
sh-4.3# cd mnt/
sh-4.3# ./embedded.elf
Started reading dataset...
Finished reading dataset...
Started reading name id mapping...
Finished reading name id mapping...
Input movie id = 0
Started distance calculations on software...
Finished distance calculations on software...
Started distance calculations on hardware...
Finished distance calculations on hardware...

Recommendation system start to make inference
...
Recommendations for movie with id 0:
0. Jurassic Park (1993), with distance of 10.7121
1. Fish Called Wanda  A (1988), with distance of 11.0793
2. Back to the Future (1985), with distance of 11.6404
3. Star Wars: Episode VI - Return of the Jedi (1983), with distance of 11.8849
4. Lion King  The (1994), with distance of 12.0623
5. Raising Arizona (1987), with distance of 12.1552
6. Wizard of Oz  The (1939), with distance of 12.1861
7. Batman (1989), with distance of 12.2066
8. Princess Bride  The (1987), with distance of 12.3085
9. E.T. the Extra-Terrestrial (1982), with distance of 12.3996

Hardware cycles : 401653
Software cycles : 1390418
Speedup         : 3.46174
Correct = 1024, Score = 1.000000
sh-4.3#
```

Για την περίπτωση **πλήρη διαμερισμού** του πίνακα `movie_tmp` κάνουμε το estimation:

Details

Performance estimates for 'calcDistancesHW in main.cpp:24 ...

HW accelerated (Estimated cycles)	392601

Resource utilization estimates for HW functions

Resource	Used	Total	% Utilization
DSP	32	80	40
BRAM	17	60	28,33
LUT	4509	17600	25,62
FF	2417	35200	6,87

Performance Estimates

Timing (ns)

Summary

Clock	Target	Estimated	Uncertainty
ap_clk	10.00	8.70	1.25

Latency (clock cycles)

Summary

Detail

Instance

Loop

	Latency			Initiation Interval			
Loop Name	min	max	Iteration Latency	achieved	target	Trip Count	Pipelined
- LOAD_DATA_HW_TMP_L	32771	32771	5	1	1	32768	yes
- LOAD_MOVIE_TMP	32	32	2	1	1	32	yes
- COMPUTE_DISTS	1054	1054	32	1	1	1024	yes
- WRITE_DISTS	1024	1024	2	1	1	1024	yes

```
sh-4.3# cd mnt/
sh-4.3# ./embedded.elf
Started reading dataset...
Finished reading dataset...
Started reading name id mapping...
Finished reading name id mapping...
Input movie id = 0
Started distance calculations on software...
Finished distance calculations on software...
Started distance calculations on hardware...
Finished distance calculations on hardware...

Recommendation system start to make inference
...
Recommendations for movie with id 0:
0. Jurassic Park (1993), with distance of 10.7121
1. Fish Called Wanda  A (1988), with distance of 11.0793
2. Back to the Future (1985), with distance of 11.6404
3. Star Wars: Episode VI - Return of the Jedi (1983), with distance of 11.8849
4. Lion King  The (1994), with distance of 12.0623
5. Raising Arizona (1987), with distance of 12.1552
6. Wizard of Oz  The (1939), with distance of 12.1861
7. Batman (1989), with distance of 12.2066
8. Princess Bride  The (1987), with distance of 12.3085
9. E.T. the Extra-Terrestrial (1982), with distance of 12.3996

Hardware cycles : 400596
Software cycles : 1390047
Speedup         : 3.46995
Correct = 1024, Score = 1.000000
sh-4.3#
```

Αποτελέσματα

1. Block Factor = 8:
    - Speedup: ~3.41
    - Μείωση Κύκλων: 3.4% σε σχέση με το block factor = 4.
2. Block Factor = 16:
    - Speedup: ~3.46
    - Μείωση Κύκλων: 4.7% σε σχέση με το block factor = 4.
    - Pipelined Design: Το achieved initiation interval (II) είναι πλέον ίσο με 1.

3. Πλήρης διαμερισμός movie_tmp:
    - Speedup: ~3.47
    - Μείωση Κύκλων: 5.1% σε σχέση με το block factor = 4.
    - Pipelined Design: Το achieved initiation interval (II) είναι ξανά ίσο με 1.

Ο διαμερισμός του πίνακα `data_hw_tmp` σε περισσότερα blocks αυξάνει τον αριθμό των παράλληλων προσβάσεων στη μνήμη. Αυτό επιτρέπει την ταυτόχρονη ανάγνωση περισσότερων δεδομένων, μειώνοντας το latency. Ο πίνακας `movie_tmp` έχει πλήρη διαμερισμό, εξασφαλίζοντας ότι κάθε στοιχείο είναι άμεσα διαθέσιμο χωρίς καθυστερήσεις.

Με block factor = 16, επιτυγχάνεται πλήρες pipelining στην **COMPUTE_DISTS** (II = 1). Αυτό σημαίνει ότι κάθε νέο iteration ξεκινά σε κάθε κύκλο ρολογιού, αυξάνοντας δραματικά τον ρυθμό επεξεργασίας.

Μετά από περαιτέρω διερεύνηση παρατηρούμε στο αρχείο `calcDist.h` τις εξής εντολές:

```
#pragma SDS data copy(data_hw[0:32768], dists_hw[0:32])
#pragma SDS data access_pattern(data_hw:SEQUENTIAL, dists_hw:SEQUENTIAL)
```

που αφορούν την μεταφορά δεδομένων των πινάκων *data_hw[]* και *dists_hw[]* από το software στο hardware.

Ανατρέχοντας στο SDSoC Environment User Guide UG1027 (v2016.4) March 9, 2017 για να καταλάβουμε περισσότερα για τα παραπάνω pragmas, διαπιστώνουμε ότι ισχύουν τα εξής για την υλοποίηση της διεπαφής μεταξύ του PS (επεξεργαστή) και του PL (FPGA):

Κάθε μεταφορά δεδομένων μεταξύ ενός software προγράμματος και μιας hardware συνάρτησης απαιτεί ένα Data Mover, αποτελούμενο από ένα hardware component που μετακινεί τα δεδομένα και μία operating system-specific library function.

Για τον **Data Mover** στο εγχειρίδιο αναγράφονται τα παρακάτω:

Data Mover

The data mover transfers data between PS and accelerators, and among accelerators. SDSoC™ can generate various types of data movers based on the properties and size of the data being transferred.

Scalar

Scalar data is always transferred by the AXI_LITE data mover.

Array

SDSoC can generate AXI_DMA_SG, AXI_DMA_SIMPLE, AXI_DMA_2D, AXI_FIFO, AXI_M, or AXI_LITE data movers, depending on the memory attributes and data size of the array. For example, if the array is allocated using `malloc()`, hence the memory is not physically contiguous, SDSoC typically generates AXI_DMA_SG. However, if the data size is less than 300 bytes, AXI_FIFO is generated instead since the data transfer time is less than AXI_DMA_SG, and it occupies much less PL resource.

Struct or Class

The implementation of structs depends on how the struct is passed to the hardware—passed by value, passed by reference, or as an arrays of structs—and the type of datamover selected. The following table shows the various implementations.

Table 1: Struct Implementations

Struct Pass Method	Default (no pragma)	#pragma SDS data zero_copy (arg)	#pragma SDS data zero_copy (arg[0:SIZE])	#pragma SDS data copy (arg)	#pragma SDS data copy (arg[0:SIZE])
pass by value (struct RGB arg)	Each field is flattened and passed individually as a scalar or an array.	This is not supported and will result in an error.	This is not supported and will result in an error.	The struct is packed into a single wide scalar.	Each field is flattened and passed individually as a scalar or an array. The value of SIZE is ignored.
pass by pointer (struct RGB *arg)	Each field is flattened and passed individually as a scalar or an array.	The struct is packed into a single wide scalar and transferred as a single value. The data is transferred to the hardware accelerator via an AXI4 bus.	The struct is packed into a single wide scalar. The number of data values transferred to the hardware accelerator via an AXI4 bus is defined by the value of SIZE.	The struct is packed into a single wide scalar.	The struct is packed into a single wide scalar. The number of data values transferred to the hardware accelerator via an AXIDMA_SG or AXIDMA_SIMPLE is defined by the value of SIZE.

array of struct (struct RGB arg[1024])	Each struct element of the array is packed into a single wide scalar.	Each struct element of the array is packed into a single wide scalar. The data is transferred to the hardware accelerator via an AXI4 bus.	Each struct element of the array is packed into a single wide scalar. The data is transferred to the hardware accelerator via an AXI4 bus.	Each struct element of the array is packed into a single wide scalar. The data is transferred to the hardware accelerator via a data mover such as AXIDMA_SG or AXIDMA_SIMPLE.	Each struct element of the array is packed into a single wide scalar. The data is transferred to the hardware accelerator via a data mover such as AXIDMA_SG or AXIDMA_SIMPLE.

Struct Pass Method	Default (no pragma)	#pragma SDS data zero_copy (arg)	#pragma SDS data zero_copy (arg[0:SIZE])	#pragma SDS data copy (arg)	#pragma SDS data copy (arg[0:SIZE])
			The value of SIZE overrides the array size and determines the number of data values transferred to the accelerator.		The value of SIZE overrides the array size and determines the number of data values transferred to the accelerator.

The selection of which data mover to use for transferring an array is dependent on two attributes of the array: data size and physical memory contiguity. For example, if the memory size is 1 MB and not physically contiguous (allocated by `malloc()`), you should use AXIDMA_SG. The following table shows the applicability of these data movers.

Table 2: Data Mover Selection

Data Mover	Physical Memory Contiguity	Data Size (bytes)
AXIDMA_SG	Either	> 300
AXIDMA_Simple	Contiguous	< 8M
AXIDMA_2D	Contiguous	< 8M
AXI_FIFO	Non-contiguous	< 300

Normally, the SDSoC™ compiler analyzes the array that is transferred to the hardware accelerator for these two attributes, and selects the appropriate data mover accordingly.

Με βάση τα παραπάνω είναι σίγουρα πιο αποδοτικό να μεταφέρουμε απευθείας τα δεδομένα του του πίνακα *dists_hw[]* αντί να το κάνουμε σε stream από 32 bit. Επομένως, στον κώδικά μας αλλάξαμε την παρακάτω γραμμή:

```
#pragma SDS data copy(data_hw[0:32768], dists_hw[0:1024])
```

Για αυτή την υλοποίηση έχουμε το παρακάτω estimation:

Details

Performance estimates for 'calcDistancesHW in main.cpp:24 ...

HW accelerated (Estimated cycles)	2147483647

Resource utilization estimates for HW functions

Resource	Used	Total	% Utilization
DSP	32	80	40
BRAM	25	60	41,67
LUT	8716	17600	49,52
FF	8015	35200	22,77

Performance Estimates

Timing (ns)

Summary

Clock	Target	Estimated	Uncertainty
ap_clk	10.00	8.70	1.25

Latency (clock cycles)

Summary

Latency		Interval		
min	max	min	max	Type
34889	34889	34890	34890	none

Detail

Instance

Loop

	Latency			Initiation Interval			
Loop Name	min	max	Iteration Latency	achieved	target	Trip Count	Pipelined
- LOAD_DATA_HW_TMP_L	32771	32771	5	1	1	32768	yes
- LOAD_MOVIE_TMP	32	32	2	1	1	32	yes
- COMPUTE_DISTS	1054	1054	32	1	1	1024	yes
- WRITE_DISTS	1024	1024	2	1	1	1024	yes

Παρατηρούμε ότι αυτή η υλοποίηση απαιτεί περισσότερα resources από τις προηγούμενες, όπως είναι άλλωστε και λογικό, αλλά βλέπουμε ότι οι HW κύκλοι αυξήθηκαν υπερβολικά πολύ χωρίς κάποια λογική εξήγηση.

Τρέχοντας όμως το αντίστοιχο bitstream στο Zybo λαμβάνουμε το παρακάτω αποτέλεσμα:

```
sh-4.3# ./embedded.elf
Started reading dataset...
Finished reading dataset...
Started reading name id mapping...
Finished reading name id mapping...
Input movie id = 0
Started distance calculations on software...
Finished distance calculations on software...
Started distance calculations on hardware...
Finished distance calculations on hardware...

Recommendation system start to make inference
...
Recommendations for movie with id 0:
0. Jurassic Park (1993), with distance of 10.7121
1. Fish Called Wanda  A (1988), with distance of 11.0793
2. Back to the Future (1985), with distance of 11.6404
3. Star Wars: Episode VI - Return of the Jedi (1983), with distance of 11.8849
4. Lion King  The (1994), with distance of 12.0623
5. Raising Arizona (1987), with distance of 12.1552
6. Wizard of Oz  The (1939), with distance of 12.1861
7. Batman (1989), with distance of 12.2066
8. Princess Bride  The (1987), with distance of 12.3085
9. E.T. the Extra-Terrestrial (1982), with distance of 12.3996

Hardware cycles : 248917
Software cycles : 1390124
Speedup         : 5.58469
Correct = 1024, Score = 1.000000
```

Επομένως, η μόνη λογική εξήγηση σχετικά με το estimation είναι ότι συμβαίνει κάποιο σφάλμα κατά την μοντελοποίηση που οδηγεί σε λανθασμένο υπολογισμό των HW κύκλων.

Τελική Υλοποίηση:

- Speedup: ~5.58
- Μείωση Κύκλων: 69.09% σε σχέση με το block factor = 4.
- Pipelined Design: Το achieved initiation interval (II) είναι ξανά ίσο με 1.

Στην τελική υλοποίηση πετυχαίνουμε πολύ καλύτερο speedup, αλλά ταυτόχρονα αυξάνουμε αρκετά το κόστος σε resources του FPGA. Επίσης, το design που έχουμε σχεδιάσει είναι Pipelined με Initiation Interval = 1, επομένως κρατάμε αυτήν ως **βέλτιστη υλοποίηση**.

Αρχεία της εργαστηριακής άσκησης

Ο τελικός κώδικας της Άσκησης 1 βρίσκεται στον φάκελο `ask1`.

Ο τελικός κώδικας της Άσκησης 2 βρίσκεται στον φάκελο `ask2`.

Ο τελικός κώδικας της Άσκησης 3 βρίσκεται στον φάκελο `ask3`.

Τα αποτελέσματα των εκτελέσεων βρίσκονται στο αρχείο `values.txt`.